

TALLER PRÁCTICO DE ANALÍTICA DE DATOS

Hábitos de vida y niveles de obesidad

¿Qué factores pesan más allá del propio peso?

Anaconda · Jupyter Notebook · Python

pandas · seaborn · matplotlib · scikit-learn

Material — Guía

Dataset: UCI Machine Learning Repository — ID 544

0. Presentación del taller

Este documento acompaña al notebook de Jupyter “Taller_Analitica_Datos_Obesidad.ipynb” y explica en detalle cada etapa del análisis: descarga de datos, limpieza, modelado, gráficos y conclusiones. Está pensado para usarse como guion con el cual se reproduce cada celda del notebook mientras se explican las decisiones tomadas en cada paso.

Herramientas necesarias

Anaconda web (anaconda.cloud) con Jupyter Notebook, y las librerías pandas, numpy, matplotlib, seaborn, scikit-learn y ucimlrepo. Instrucciones de acceso en la sección 4.

Objetivos

1. Practicar el flujo completo de un proyecto de analítica de datos: descarga → limpieza → modelado → visualización → conclusiones.
2. Aprender a formular una pregunta de análisis concreta y contrastarla con datos.
3. Detectar y evitar un error metodológico muy común: la fuga de datos (data leakage).
4. Entrenar e interpretar un modelo de clasificación (Random Forest) con scikit-learn.
5. Comunicar resultados mediante gráficos claros y conclusiones accionables.

Estructura

1. La pregunta clave
2. Dataset utilizado
3. Origen de los datos
4. Preparar el entorno con Anaconda web
5. Descarga del dataset
6. Exploración inicial y limpieza de datos
7. Análisis exploratorio (EDA) y gráficos
8. Preparación de datos para el modelo
9. Modelo A — control (fuga de datos)
10. Modelo B — el modelo que responde la pregunta
11. Importancia de variables
12. Conclusiones
13. Ideas para extender el taller
14. Referencias del dataset

1. La pregunta clave

Pregunta de análisis

¿Qué hábitos de vida y factores sociodemográficos están más asociados con el nivel de obesidad de una persona, más allá del propio peso y la altura?

Esta pregunta obliga a ir más allá de un simple ejercicio de predicción: no basta con lograr un modelo con alta exactitud, hay que asegurarse de que el modelo aprende algo relevante para la pregunta de salud pública planteada, y no un atajo matemático. Por eso el taller compara dos modelos: uno que incluye peso y altura (control) y otro que los excluye deliberadamente (el que realmente responde la pregunta).

2. Dataset utilizado

Se utiliza el conjunto de datos público “Estimation of Obesity Levels Based on Eating Habits and Physical Condition”, publicado en el UCI Machine Learning Repository (identificador 544) por Palechor y de la Hoz Manotas (2019). Contiene 2111 registros de personas de Colombia, Perú y México, con 17 atributos sobre alimentación, actividad física, transporte y datos demográficos, más una variable objetivo con 7 niveles de obesidad.

El 23% de los registros proviene de una encuesta real realizada mediante una plataforma web; el 77% restante se generó de forma sintética con la herramienta Weka y el filtro SMOTE para balancear las categorías. Esta es una limitación importante a comunicar: las conclusiones del taller son asociaciones observadas en esta muestra, no relaciones causales universales.

Columna	Significado
Gender, Age, Height, Weight	Datos demográficos y antropométricos
family_history_with_overweight	¿Algún familiar ha tenido sobrepeso?
FAVC	Consumo frecuente de alimentos hipercalóricos
FCVC	Frecuencia de consumo de vegetales
NCP	Número de comidas principales al día
CAEC	Consumo de alimentos entre comidas
SMOKE	Fuma
CH2O	Consumo diario de agua
SCC	Monitorea las calorías que consume
FAF	Frecuencia de actividad física

TUE	Tiempo de uso de dispositivos electrónicos
CALC	Consumo de alcohol
MTRANS	Medio de transporte habitual
NObeyesdad	Variable objetivo: nivel de obesidad (7 categorías)

3. Origen de los datos

3.1 ¿De dónde vienen exactamente estos datos?

Los datos fueron recopilados y publicados por Fernando Mendoza Palechor y Alexis de la Hoz Manotas, quienes documentaron su origen en el artículo científico “Dataset for estimation of obesity levels based on eating habits and physical condition in individuals from Colombia, Peru and Mexico”, publicado en 2019 en la revista Data in Brief (editorial Elsevier). Los participantes son personas de Colombia, Perú y México, con edades entre 14 y 61 años.

La recolección tiene dos componentes bien diferenciados:

- 23% de los registros son reales: se obtuvieron mediante una encuesta anónima publicada en una plataforma web, donde cada persona respondía preguntas sobre su alimentación, actividad física, transporte habitual y otros hábitos.
- 77% de los registros son sintéticos: se generaron artificialmente con la herramienta Weka y el filtro SMOTE (Synthetic Minority Over-sampling Technique), una técnica estadística que crea registros nuevos interpolando entre los datos reales, con el fin de balancear el número de personas en cada una de las siete categorías de obesidad.

Por qué esto importa para el análisis

La mayoría de las filas del dataset no corresponden a personas reales, sino a datos generados estadísticamente a partir de las respuestas reales. Los patrones que encuentra el modelo (por ejemplo, la relación entre actividad física y nivel de obesidad) reflejan sobre todo la estructura de esa encuesta original, amplificada por SMOTE. Las conclusiones del taller deben presentarse como asociaciones dentro de esta muestra concreta, no como hechos clínicos universales.

El etiquetado del nivel de obesidad de cada persona (variable NObeyesdad) se realizó aplicando la normativa mexicana de salud y los criterios de la Organización Mundial de la Salud (OMS) sobre el Índice de Masa Corporal — el mismo criterio que se verifica de forma independiente en la sección 5 de este documento.

3.2 ¿Qué es el UCI Machine Learning Repository?

El UCI Machine Learning Repository es una biblioteca pública de conjuntos de datos para aprendizaje automático y análisis de datos, mantenida por la Universidad de California en Irvine (UC Irvine) desde 1987. Es una de las fuentes de datos más antiguas, citadas y utilizadas en el ámbito académico y profesional de la ciencia de datos: datasets tan conocidos como Iris o el propio Titanic también están alojados allí.

Cada dataset del repositorio incluye, además de los datos en sí:

- Documentación de cada variable/columna.
- El número de registros y la metodología de recolección.
- La cita académica del artículo o estudio que originó los datos.
- Una licencia de uso clara (en este caso, Creative Commons Attribution 4.0, que permite el uso libre citando la fuente).

Este dataset en particular tiene el identificador 544 dentro del repositorio, y puede descargarse mediante el paquete oficial de Python ucimlrepo (ver siguiente sección) o consultarse directamente en archive.ics.uci.edu.

4. Etapa 1 — Preparar el entorno con Anaconda web

Este taller está pensado para ejecutarse en Anaconda web (anaconda.cloud), sin necesidad de instalar nada en el ordenador. Los pasos previos, antes de tocar una sola celda de código, son los siguientes:

- Entrar en anaconda.cloud e iniciar sesión con una cuenta de Anaconda (o crear una gratuita si no se tiene).
- Abrir un notebook session: un entorno Jupyter que corre en la nube, ya con Python y las librerías de ciencia de datos más comunes preinstaladas.
- Importar el archivo del taller (`Taller_Analitica_Datos_Obesidad.ipynb`) con la opción de subir/importar notebook (Upload / Import notebook).
- Ejecutar la primera celda de código, que importa las librerías necesarias (pandas, numpy, matplotlib, seaborn, scikit-learn). Si el entorno no trae instalada alguna librería concreta — por ejemplo ucimlrepo, el paquete oficial para descargar datasets de la UCI—, se instala directamente desde una celda con `%pip install ucimlrepo`, sin salir del navegador.
- A partir de ahí, todas las celdas se ejecutan en orden, de arriba hacia abajo, directamente desde la interfaz web.

La ventaja de este enfoque es que no se necesita instalar Anaconda en el propio ordenador ni resolver problemas de configuración local: solo se necesita un navegador y una cuenta.

5. Etapa 2 — Descarga del dataset

El notebook descarga los datos con el paquete oficial `ucimlrepo`, mantenido por la propia UCI, que se conecta directamente a la fuente original sin necesidad de guardar copias manuales del archivo. Como plan B (por ejemplo, si la red del aula bloquea ese dominio), el notebook incluye una descarga alternativa desde una copia CSV de solo lectura del mismo dataset, para que la demostración nunca se detenga por un problema de conectividad.

6. Etapa 3 — Exploración inicial y limpieza

Se revisan tipos de datos, valores nulos y filas duplicadas. El dataset no tiene valores nulos, pero sí 24 filas duplicadas exactas (probablemente relacionado al proceso de generación sintética), que se eliminan, quedando 2 087 registros. También se verifican los rangos de edad (14–61 años), altura (1.45–1.98 m) y peso (39–173 kg), que resultan plausibles para una muestra de población general.

A continuación se calcula el Índice de Masa Corporal ($\text{IMC} = \text{peso} / \text{altura}^2$) para cada persona y se compara contra la categoría de obesidad asignada:

Categoría	IMC mínimo	IMC máximo	IMC promedio
Peso insuficiente	13.0	19.1	17.4
Peso normal	18.5	24.9	22.0
Sobrepeso I	22.8	28.8	26.0
Sobrepeso II	25.7	30.4	28.2
Obesidad I	29.9	35.2	32.3
Obesidad II	34.0	39.8	36.7
Obesidad III	36.8	50.8	42.3

Tabla 1. Rango de IMC observado dentro de cada categoría del dataset.

Hallazgo clave — fuga de datos (data leakage)

Los rangos de IMC por categoría no se solapan y coinciden casi exactamente con los umbrales clínicos estándar (bajo peso < 18.5, normal 18.5–25, sobrepeso 25–30, obesidad > 30). Esto confirma que la variable objetivo fue etiquetada directamente a partir del peso y la altura. Un modelo que use esas dos variables como entrada no aprende hábitos: solo recalcula una fórmula. Por eso deben excluirse del modelo que responde la pregunta del taller.

7. Etapa 4 — Análisis exploratorio (EDA)

7.1 Distribución de la variable objetivo




Figura 1. Número de personas por categoría de obesidad.

Las siete categorías están razonablemente balanceadas (entre 272 y 351 personas cada una), lo que evita la necesidad de técnicas adicionales de rebalanceo antes de entrenar el modelo.

7.2 Verificación visual del criterio de etiquetado




Figura 2. Distribución del IMC calculado dentro de cada categoría, sin solapamientos.

7.3 Correlación entre variables numéricas




Figura 3. Matriz de correlación de Pearson entre variables numéricas.

El peso y el IMC están fuertemente correlacionados (> 0.9), como es esperable. Ninguna variable de hábito muestra por sí sola una correlación lineal fuerte con el IMC, lo que sugiere que su efecto conjunto es más complejo y no lineal — un escenario adecuado para un modelo basado en árboles como Random Forest.

8. Etapa 5 — Preparación de los datos para el modelo

Se codifican las variables categóricas para que el modelo pueda utilizarlas:

- Variables binarias (sí/no) → 0/1 (antecedentes familiares, consumo de comida hipercalórica, fumar, monitoreo de calorías).
- Variables ordinales (nunca / a veces / frecuente / siempre) → 0-3 (picoteo entre comidas, consumo de alcohol).
- Género → 0/1.
- Medio de transporte (sin orden natural) → codificación one-hot.

9. Etapa 6 — Modelo A: control con fuga de datos

Se entrena un RandomForestClassifier (300 árboles) incluyendo peso y altura como variables de entrada, a modo de control. El objetivo no es usar este modelo para sacar conclusiones, sino demostrar el efecto de la fuga de datos detectada en la sección 5.

Matriz de confusión — Modelo A (incluye peso/altura)
Exactitud = 95.9%

	Peso insuficiente	Peso normal	Sobrepeso I	Sobrepeso II	Obesidad I	Obesidad II	Obesidad III
Real							
Peso insuficiente	50	3	0	0	0	0	0
Peso normal	0	55	0	0	0	2	0
Sobrepeso I	0	0	68	0	0	0	2
Sobrepeso II	0	0	0	60	0	0	0
Obesidad I	0	0	1	0	64	0	0
Obesidad II	0	5	0	0	0	50	0
Obesidad III	0	2	0	0	0	2	54
	Peso insuficiente	Peso normal	Sobrepeso I	Sobrepeso II	Obesidad I	Obesidad II	Obesidad III
	Predicción						

Figura 4. Matriz de confusión del Modelo A — exactitud 95.9%.

Como se anticipaba, la exactitud es muy alta y los pocos errores se concentran entre categorías adyacentes (por ejemplo, Obesidad I y Obesidad II). El modelo no está detectando patrones de comportamiento: está recalculando el IMC a partir de sus propios ingredientes. Este resultado, aunque impresionante a primera vista, no responde a la pregunta del taller.

10. Etapa 7 — Modelo B: el modelo que responde la pregunta

Se repite el entrenamiento (Random Forest, 400 árboles, profundidad máxima 12) excluyendo explícitamente peso, altura e IMC. Solo quedan variables de hábitos (alimentación, actividad física, transporte, uso de pantallas) y demografía (edad, género, antecedentes familiares).

Matriz de confusión — Modelo B (solo hábitos/demografía)
Exactitud = 84.0%

Real	Peso insuficiente	49	3	0	0	0	0	1
	Peso normal	2	42	2	0	0	6	5
	Sobrepeso I	0	2	62	3	0	1	2
	Sobrepeso II	0	1	0	57	0	1	1
	Obesidad I	0	1	0	0	64	0	0
	Obesidad II	2	7	6	0	0	39	1
	Obesidad III	1	6	5	4	0	4	38
		Peso insuficiente	Peso normal	Sobrepeso I	Sobrepeso II	Obesidad I	Obesidad II	Obesidad III
		Predicción						

Figura 5. Matriz de confusión del Modelo B — exactitud 84.0%.

Sin peso ni altura, el modelo mantiene una exactitud del 84%, muy por encima del azar (~14% con 7 categorías). Esto demuestra que los hábitos de vida contienen señal real y aprovechable para estimar el nivel de obesidad de una persona, aunque —lógicamente— con menos precisión que si se usara directamente el peso.

11. Etapa 8 — Importancia de variables




Figura 6. Importancia relativa de cada hábito/factor demográfico en el Modelo B.

Orden	Factor	Interpretación
1	Edad	Los hábitos y el metabolismo varían con la etapa de vida
2	Consumo de vegetales (FCVC)	Mayor frecuencia se asocia a categorías más bajas de obesidad
3	N° de comidas principales (NCP)	Patrones alimenticios estructurados vs. picoteo
4	Actividad física (FAF)	Frecuencia de ejercicio semanal
5	Tiempo en pantallas (TUE)	Proxy de sedentarismo
6	Consumo de agua (CH2O)	Asociado a hábitos alimenticios más saludables
7	Género	Diferencias fisiológicas y de hábitos entre hombres y mujeres
8	Antecedentes familiares	Componente genético/ambiental compartido en el hogar

Tabla 2. Interpretación de los factores más influyentes del Modelo B.

12. Conclusiones

Retomando la pregunta clave del taller, el análisis permite concluir lo siguiente:

- La etiqueta del dataset está definida directamente por el IMC: un modelo que incluya peso y altura solo redescubre esa fórmula (Modelo A, 95.9% de exactitud) y constituye un ejemplo claro de fuga de datos.
- Los hábitos de vida, por sí solos, predicen razonablemente bien el nivel de obesidad (Modelo B, 84.0% de exactitud sin usar peso ni altura).
- Los factores más asociados son, en orden aproximado de importancia: edad, frecuencia de consumo de vegetales, número de comidas principales al día, frecuencia de actividad física, tiempo frente a pantallas, consumo diario de agua, género y antecedentes familiares de sobrepeso.
- Implicación práctica: una intervención de salud centrada en promover el consumo de vegetales, la actividad física regular, reducir el tiempo de pantalla y estructurar los horarios de comida tiene, según estos datos, más potencial de asociarse a un menor nivel de obesidad que solo “vigilar el peso”.

Limitaciones a comunicar

El 77% de los registros del dataset es sintético (generado con SMOTE) y la muestra proviene solo de tres países. Las conclusiones deben presentarse como asociaciones encontradas en esta muestra concreta, no como relaciones causales generalizables a cualquier población.

13. Ideas para extender el taller

- Probar otros algoritmos (regresión logística, XGBoost) y comparar exactitud e interpretabilidad frente al Random Forest.
- Aplicar SHAP para explicar predicciones individuales, no solo la importancia global de variables.
- Reformular el problema como regresión directa sobre el IMC en lugar de clasificación por categorías.
- Explorar interacciones entre variables, por ejemplo actividad física × antecedentes familiares.

14. Referencia del dataset

Palechor, F. M., & de la Hoz Manotas, A. (2019). Dataset for estimation of obesity levels based on eating habits and physical condition in individuals from Colombia, Peru and Mexico. UCI Machine Learning Repository. <https://doi.org/10.24432/C5H31Z>