

Taller de analítica de datos

Factores de peso: hábitos de vida y niveles de obesidad

Miguel Jaime Correa

Ing. Superior en Informática – Formador TI

IEEE Senior Member

09/2026

Agenda

- Introducción y contexto
- Tecnologías utilizadas
- Demostración completa de las etapas del proceso de análisis de datos
- Ideas y alternativas de extensión del análisis
- Material compartido
- Q&A

Introducción y contexto

Análisis de hábitos de vida y obesidad

© PREGUNTA CLAVE DEL CASO

¿Qué hábitos de vida y factores sociodemográficos están más asociados al nivel de obesidad de una persona, más allá del propio peso y la altura?



Origen de los Datos


- **Dataset UCI 544:** Muestra representativa de 2.111 personas de Colombia, Perú y México.
- **17 Variables:** Alimentación, actividad física, transporte y perfil demográfico.
- **Variable Objetivo:** Nivel de obesidad clasificado en 7 categorías clínicas.



El Reto: Data Leakage

- **Fuga de Información:** La etiqueta fue calculada matemáticamente con la fórmula del IMC.
- **Estrategia del Taller:** Excluimos deliberadamente peso y altura del modelo.

💡 **Decisión de negocio:** Buscar insights accionables sobre hábitos, no reaprender fórmulas matemáticas.



2.111

REGISTROS

17

VARIABLES

Python


pandas

scikit-learn

seaborn

Tecnologías utilizadas

Nuestra caja de herramientas



Tecnologías utilizadas

Enviroment

Anaconda Web es un entorno de desarrollo interactivo basado en la nube que permite escribir, ejecutar y compartir código en Python y R directamente desde un navegador web, sin necesidad de realizar ninguna instalación local en tu ordenador.

Características principales

- **Cero instalación**
- **Jupyter Notebooks integrados:** Aplicación web interactiva que permite crear y compartir documentos que combinan código ejecutable (en lenguajes como Python), texto explicativo, ecuaciones y visualizaciones gráficas en un solo lugar.
- **Librerías preinstaladas:** Incluye por defecto las bibliotecas fundamentales para Ciencia de Datos y Machine Learning (como pandas, scikit-learn, matplotlib y seaborn).
- **Entorno en la nube:** Ejecuta las operaciones computacionales en los servidores de Anaconda, permitiendo trabajar desde cualquier dispositivo.

Tecnologías utilizadas

Language & Libraries

Python: Lenguaje de programación versátil, claro y legible, estándar en ciencia de datos y aprendizaje automático.

- **Pandas:** Librería para manipular, limpiar y analizar datos estructurados en tablas (DataFrames).
- **Matplotlib:** Librería base para la creación de gráficos y visualizaciones estáticas en dos dimensiones.
- **Seaborn:** Librería de visualización construida sobre Matplotlib, especializada en gráficos estadísticos atractivos y complejos.
- **Scikit-learn:** Librería de Machine Learning para preparar datos, entrenar modelos (como Random Forest) y evaluar su precisión.

Tecnologías utilizadas

Machine Learning (Random Forest)

Machine Learning: Rama de la inteligencia artificial que permite a las computadoras aprender patrones a partir de datos sin ser programadas explícitamente, mejorando sus predicciones a medida que procesan más información.

Random Forest: Algoritmo de aprendizaje supervisado que entrena un conjunto de múltiples árboles de decisión independientes y combina sus resultados para obtener una predicción final más precisa y estable.

¿Por qué se usa Random Forest en este escenario?

- **Captura relaciones complejas y no lineales**
- **Manejo de datos mixtos:** Soporta de forma nativa la combinación de variables numéricas (como la edad o el consumo de agua) y categóricas (como el tipo de transporte o los hábitos de picoteo) sin requerir escalado complejo de datos.
- **Resistencia al sobreajuste (*overfitting*):** Al promediar las decisiones de cientos de árboles, el algoritmo ofrece una excelente capacidad de generalización sobre datos no vistos.
- **Proporciona la importancia de cada variable:** Permite extraer de manera transparente cuáles factores tienen mayor peso en las predicciones.

Tecnologías utilizadas

Distribution (GitHub)


GitHub es una plataforma basada en la nube que permite a los desarrolladores alojar, gestionar, rastrear y colaborar en proyectos de código fuente y software.

Utiliza **Git**, un sistema de control de versiones que registra los cambios realizados en el código a lo largo del tiempo, permitiendo a varios profesionales trabajar simultáneamente en el mismo proyecto sin sobrescribir el trabajo de los demás.

En el contexto del presente taller, GitHub se utiliza principalmente como un **repositorio de almacenamiento accesible**, donde se guarda y distribuye el código, los archivos de datos (como el respaldo CSV del dataset) o el propio *notebook* de Jupyter para que cualquiera pueda descargarlos o ejecutarlos fácilmente vía internet.

Demostración del proceso

Seguiremos el proceso guiado de acuerdo a lo volcado en el documento Taller_Analitica_Datos_Obesidad.pdf a través del entorno Cloud



Ideas y alternativas de extensión del análisis de datos

- Probar otros algoritmos (regresión logística, XGBoost) y comparar exactitud e interpretabilidad frente al Random Forest.
- Aplicar SHAP para explicar predicciones individuales, no solo la importancia global de variables.
- Reformular el problema como regresión directa sobre el IMC en lugar de clasificación por categorías.
- Explorar interacciones entre variables, por ejemplo actividad física × antecedentes familiares.

Material compartido

El material del taller se encuentra compartido en **GitHub** :

<https://github.com/mjaimeittrainer-rgb/taller-analiticadatos-obesidad>

Y consta de:

- ✓ Fichero de desarrollo del taller Taller_Analitica_Datos_Obesidad.pdf
- ✓ Notebook de Jupyter Taller_Analitica_Datos_Obesidad.ipynb
- ✓ Fichero de presentación del taller TallerAnaliticaDatos_Presentacion.pdf
- ✓ Fichero del dataset utilizado ObesityDataSet.csv

Gracias

Miguel Jaime Correa

mjaime@ieee.org

www.linkedin.com/in/ingmigueljaimecorrea



© 2026, Miguel Jaime Correa. Alguns drets reservats / Algunos derechos reservados / Some rights reserved.

ESP: Este contenido está sujeto a una licencia **Creative Commons Atribución-NoComercial-CompartirIgual 4.0 Internacional**. Contenido de terceros (imágenes, logos y marca) excluido. Creación de contenido asistida por IA.

ENG: This content is licensed under a **Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International License**. Third-party content (images, logos, and branding) excluded. AI-assisted content.